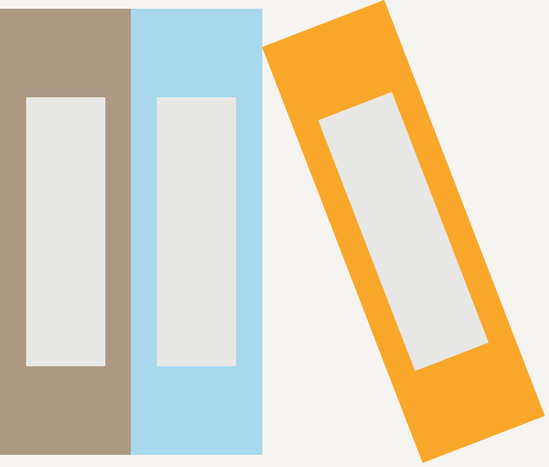




Clustering Analysis Using K-Means & Hierarchical

PROJECT 3

Contents

Project Overview

1 Degrees That Pay Back

2 Salaries By College Type

3 Salaries By Region

Overall Summary

Project Overview

ศึกษาการจัดกลุ่มด้วย **K-Means** และ **Hierarchical**
บนข้อมูลเงินเดือน 3 Datasets เพื่อ**ค้นหาโครงสร้าง** ลักษณะของกลุ่ม
และ**เปรียบเทียบผลลัพธ์ของทั้งสอง Algorithms**

Degrees That Pay Back	50 instances
Salaries by College Type	269 instances
Salaries by Region	320 instances

Data Preparation

	Dataset	Data Exploration	Data Preparation
1	Degrees That Pay Back	-	• Numerical Features • Standard Scaling
2	Salaries by College Type	**WU** Missing Values	• **Median Imputation** • Numerical Features • Standard Scaling
3	Salaries by Region	**WU** Missing Values	• **Median Imputation** • Numerical Features • Standard Scaling

Metrics Evaluation

Main

Silhouette Score

ใช้พิจารณา**ความใกล้เคียงของข้อมูลภายใน**กลุ่มเดียวกัน
และ
ความแตกต่างจากกลุ่มอื่น
ค่าสูงกว่าแสดงว่า Cluster กระชับและแยกจากกันชัดกว่า

SSE

ใช้**สร้าง Elbow Plot**
สนับสนุนการเลือก K
พิจารณาจุดที่การลดลงของ SSE เริ่มช้าลง

NMI

ใช้ตรวจสอบ
ความสอดคล้องกับ Ground Truth ในภายหลัง ค่าสูงแสดงว่า Cluster สอดคล้องกับ Ground Truth

K-Means

Experimental Plan

Round 1: number of clusters

Objective

เพื่อศึกษาผลของ**จำนวน Cluster** (n_clusters) ต่อ Performance ของ KMeans และ**หาจำนวน Cluster ที่เหมาะสมที่สุดสำหรับชุดข้อมูลนี้**

Fixed Parameters:
init='k-means++', n_init=20, max_iter=300, tol=0.0001, algorithm='lloyd' และ random_state=42

Experiment	n_clusters
K1	2
K2	3
K3	4
K4	5
K5	6
K6	7
K7	8
K8	9
K9	10

K-Means

Experimental Plan

Round 2: init × n_init

Objective

เพื่อศึกษาผลของ**วิธีเลือก Centroid เริ่มต้น** (init) และ**จำนวนครั้งในการเริ่มต้นใหม่** (n_init) ต่อ Performance ของ KMeans และ**หา Configuration ที่เหมาะสมที่สุดสำหรับชุดข้อมูลนี้**

Fixed Parameters:
n_clusters=Best K จาก Round 1, max_iter=300, tol=0.0001, algorithm='lloyd' และ random_state=42

Experiment	n_clusters	init	n_init
K10	**Best K**	k-means++	1
K11	**Best K**	k-means++	10
K12	**Best K**	k-means++	20
K13	**Best K**	k-means++	50
K14	**Best K**	random	1
K15	**Best K**	random	10
K16	**Best K**	random	20
K17	**Best K**	random	50

Experimental Plan

Hierarchical

Round 1: number of clusters

Objective

เพื่อศึกษาผลของ**จำนวน Cluster** (n_clusters) ต่อ Performance ของ Hierarchical และ**หาจำนวน Cluster ที่เหมาะสมที่สุดสำหรับชุดข้อมูลนี้**

Fixed Parameters:
linkage='ward' และ metric='euclidean'
ส่วน Parameters อื่นใช้ค่า Default ของ scikit-learn

Experiment	n_clusters
H1	2
H2	3
H3	4
H4	5
H5	6
H6	7
H7	8
H8	9
H9	10

Experimental Plan

Hierarchical

Round 2: linkage × metric

Objective

เพื่อศึกษาผลของ**วิธีวัดระยะห่างระหว่าง cluster** (linkage) และ **วิธีวัดระหว่างจุดข้อมูล**(metric) ต่อ Performance ของ Hierarchical และหา **Configuration ที่เหมาะสมที่สุดสำหรับชุดข้อมูลนี้**

Fixed Parameters:
n_clusters=Best K จาก Round 1
ส่วน Parameters อื่นใช้ค่า Default ของ scikit-learn

Experiment	n_clusters	linkage	metric
H10	**Best K**	ward	euclidean
H11	**Best K**	complete	euclidean
H12	**Best K**	complete	manhattan
H13	**Best K**	complete	cosine
H14	**Best K**	average	euclidean
H15	**Best K**	average	manhattan
H16	**Best K**	average	cosine
H17	**Best K**	single	euclidean
H18	**Best K**	single	manhattan
H19	**Best K**	single	cosine

Contents

Project Overview

1 Degrees That Pay Back

2 Salaries By College Type

3 Salaries By Region

Overall Summary

1: Degrees That Pay Back

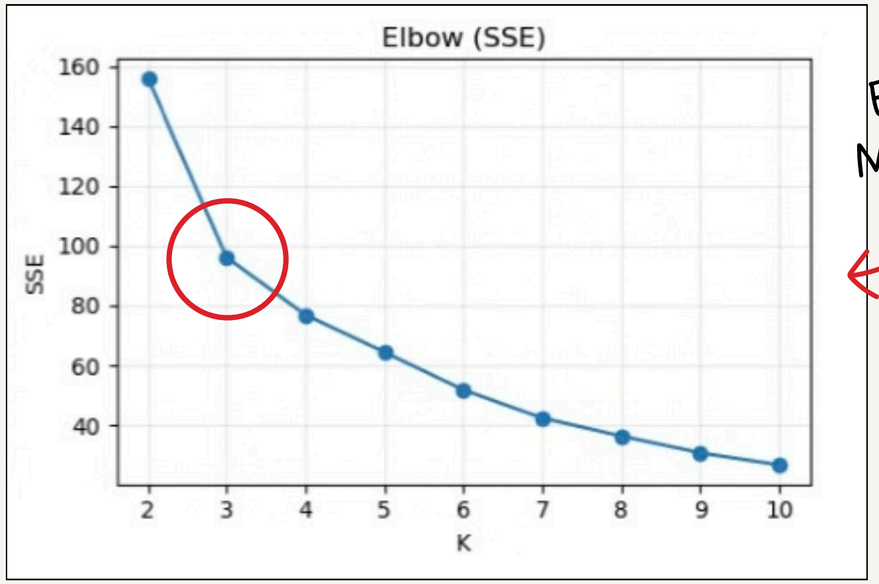
“สาขาวิชาใดมีลักษณะเงินเดือนคล้ายกัน
และแต่ละกลุ่มแตกต่างกันอย่างไร”

K-Means

1: Degrees That Pay Back

Round 1: number of clusters

Experiment	n_clusters	silhouette
K1	2	**0.4577**
K2	3	0.4205
K3	4	0.3645
K4	5	0.3334
K5	6	0.3489
K6	7	0.3592
K7	8	0.3438
K8	9	0.3364
K9	10	0.3168



Elbow Method

K-Means

1: Degrees That Pay Back

Round 1: number of clusters

Criteria	K=2	K=3
Silhouette Score	**0.4577**	0.4205
SSE	**155.91**	96.1
Cluster Size	**[23, 27]**	[12, 17, 21]
Cluster Profile	**รายได้สูง vs ต่ำ–กลาง**	แยกกลุ่ม Growth สูงเพิ่มเติม

- **K=2 ให้ Silhouette สูงสุด** และแบ่งสมาชิกเป็น [23, 27] สาขา
- **K=3 ลด SSE** และ**แยกกลุ่มรายได้ปานกลางแต่ Growth สูงเพิ่มเติม**
- เนื่องจาก K=2 แบ่งโครงสร้างหลักตามระดับเงินเดือนได้ชัดเจนกว่า และให้ Silhouette สูงกว่า ซึ่งเป็นเกณฑ์หลัก
- จึงเลือก **K=2** เป็น Fixed Parameter ใน Round 2

K-Means

1: Degrees That Pay Back

Round 2: init × n_init

Experiment	n_clusters	init	n_init	silhouette
K10	**2**	k-means++	1	**0.4577**
K11	**2**	k-means++	10	**0.4577**
K12	**2**	k-means++	20	**0.4577**
K13	**2**	k-means++	50	**0.4577**
K14	**2**	random	1	**0.4577**
K15	**2**	random	10	**0.4577**
K16	**2**	random	20	**0.4577**
K17	**2**	random	50	**0.4577**

K-Means

1: Degrees That Pay Back

Round 2: init × n_init

init × n_init	Silhouette	Cluster size	Cluster Profile
All	**0.4577**	[23, 27]	รายได้สูง vs ต่ำ–กลาง

- ทั้ง **8 Experiments ให้ Silhouette** และ **Cluster เหมือนกัน**
- การเปลี่ยน **init และ n_init จึงไม่ส่งผลต่อ Performance** ภายใต้ K=2 และ random_state = 42
- อาจเป็นเพราะ โครงสร้างหลักของข้อมูลมีการแบ่งเป็นสองกลุ่มที่ค่อนข้างเด่น ทำให้จุดเริ่มต้นที่ทดลองต่างกันยังลู่เข้าสู่คำตอบเดียวกัน
- จึงเลือก **k-means++, n_init=10** เพราะให้ผลเท่ากันโดย**ไม่ต้องเพิ่มจำนวนการเริ่มต้นมากเกินจำเป็น**

Hierarchical

1: Degrees That Pay Back

Round 1: number of clusters

Experiment	n_clusters	silhouette
H1	2	**0.4802**
H2	3	0.3867
H3	4	0.4156
H4	5	0.4026
H5	6	0.3668
H6	7	0.3051
H7	8	0.3082
H8	9	0.2938
H9	10	0.3024

Hierarchical

1: Degrees That Pay Back

Round 1: number of clusters

Criteria	K=2
Silhouette Score	0.4802
Cluster Size	[15, 35]
Cluster Profile	**รายได้สูง vs ต่ำ–กลาง**

- **K=2 ให้ Silhouette สูงสุด** และแบ่งสมาชิกเป็น [15, 35] สาขา
- เมื่อ**เพิ่ม K คะแนนลดลงโดยรวม** และบางค่าเริ่ม**เกิด Cluster ขนาดเล็ก**
- K=2 จึงสะท้อนโครงสร้างรายได้สูงกับกลุ่มทั่วไปได้ชัดกว่า โดยไม่แบ่งกลุ่มย่อยละเอียดเกินจำเป็น
- จึงเลือก **K=2** เป็น Fixed Parameter ใน Round 2

Hierarchical

1: Degrees That Pay Back

Round 2: linkage × metric

Experiment	n_clusters	linkage	metric	silhouette
H10	**2**	ward	euclidean	**0.4802**
H11	**2**	complete	euclidean	0.4394
H12	**2**	complete	manhattan	0.4394
H13	**2**	complete	cosine	0.4414
H14	**2**	average	euclidean	0.3351
H15	**2**	average	manhattan	0.3704
H16	**2**	average	cosine	0.4414
H17	**2**	single	euclidean	0.3704
H18	**2**	single	manhattan	0.3704
H19	**2**	single	cosine	0.4309

Hierarchical

1: Degrees That Pay Back

Round 2: linkage × metric

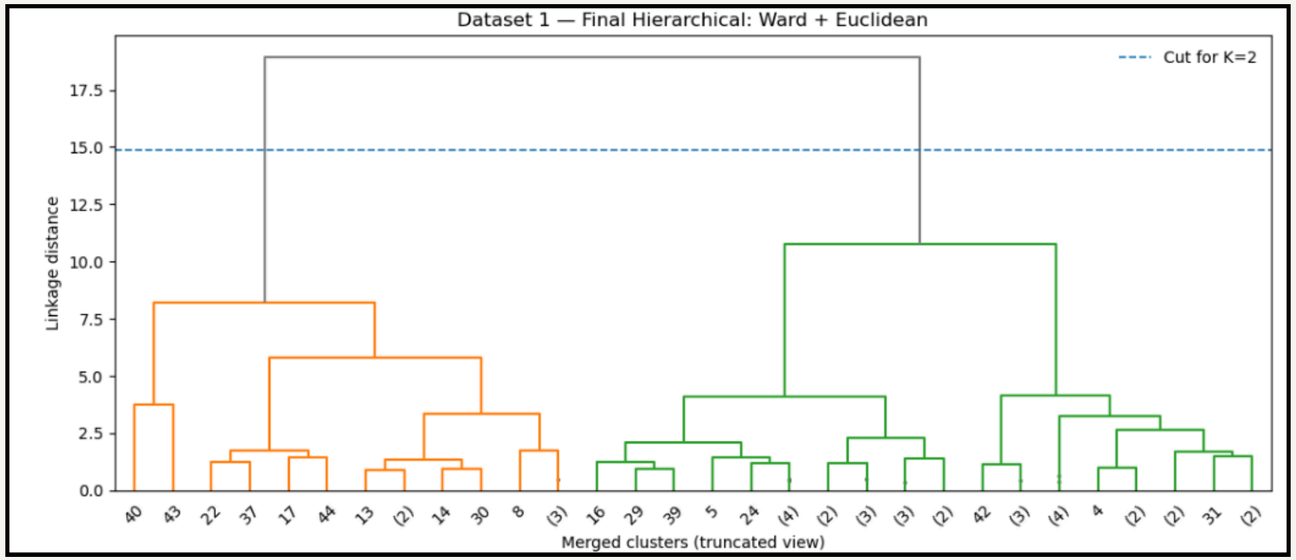
linkage × metric	Silhouette	Cluster size	Cluster Profile
Ward + Euclidean	0.4802	[15, 35]	รายได้สูง vs ต่ำ–กลาง

- **Ward + Euclidean ให้ Silhouette สูงสุด** และแบ่งสมาชิกเป็น [15, 35]
- **Configuration อื่นให้ Silhouette ต่ำกว่า** และบางแบบแยกสมาชิกจำนวนน้อยออกจากกลุ่มใหญ่
- **Ward** อาจเหมาะกับข้อมูลนี้เพราะ**ลดการเพิ่มขึ้นของความแปรปรวนภายในกลุ่ม**
  จึงสร้าง Cluster ที่กระชับกว่า

Hierarchical

1: Degrees That Pay Back

Round 2: linkage × metric



Ward + Euclidean **[15, 35]**

- **Dendrogram** แสดง **2 กลุ่มหลักที่แยกออกจากกันค่อนข้างชัดเจน** โดยได้ Cluster ขนาด [15, 35]
- สมาชิกภายในแต่ละกลุ่มรวมตัวกันก่อนที่สองกลุ่มหลักจะรวมเข้าหากัน จึง**สนับสนุนการแบ่งเป็น K=2**
- จึงเลือก **Ward + Euclidean** เป็น Final Hierarchical Configuration

1: Degrees That Pay Back

Kmeans vs Hierarchical

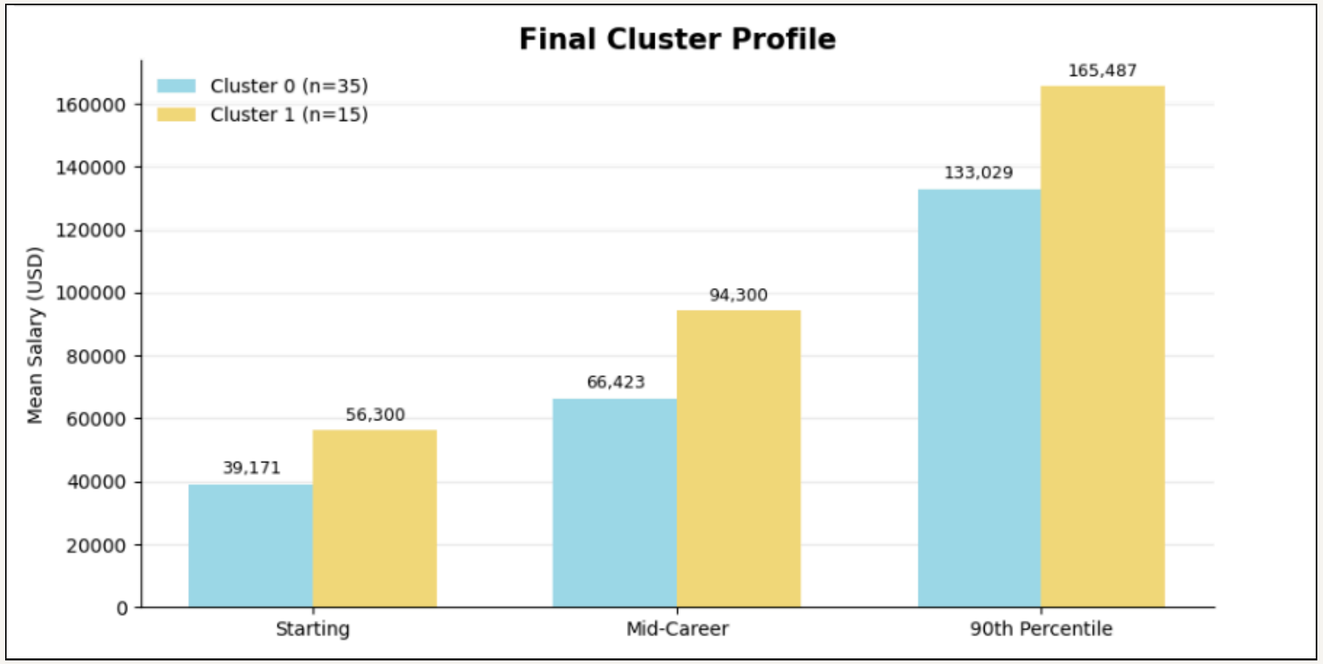
Algorithm	Silhouette	Cluster Size	Configuration
KMeans	0.4577	[23, 27]	k-means++, n_init=10
Hierarchical	**0.4802**	**[15, 35]**	**Ward + Euclidean**

- **KMeans ให้ Cluster Size สมดุลกว่า** และแยก Salary Profile เป็นกลุ่มทั่วไปกับกลุ่มสูงใน**ภาพกว้าง**
- **Hierarchical ให้ Silhouette สูงกว่า** โดยแยกกลุ่มรายได้สูงที่มี Salary Profile **เด่นออกจากกลุ่มทั่วไป**
- ผลอาจเกิดจาก Ward Linkage สร้างกลุ่มที่กระชับได้เหมาะกับโครงสร้างของ Salary Features ชุดนี้
- จึงเลือก **Hierarchical : Ward + Euclidean, K=2** เป็น Final Model ตามเกณฑ์หลักและผลการตรวจ Profile

1: Degrees That Pay Back

Hierarchical

สามารถแบ่งสาขาตามลักษณะเงินเดือน
ได้เป็น 2 กลุ่มหลัก คือ **กลุ่มรายได้ต่ำ–กลาง** และ**กลุ่มรายได้สูง**
โดยความแตกต่างหลักอยู่ที่**ระดับเงินเดือน**ในแต่ละช่วงอาชีพ
ขณะที่**อัตราการเติบโตเฉลี่ยใกล้เคียงกัน**



Cluster 0 (35 สาขา):
กลุ่มรายได้ต่ำ–กลาง มีระดับเงินเดือนใกล้เคียงกันในช่วงต่ำ–กลาง เช่น Accounting, Biology, Education, Marketing และ Sociology

Cluster 1 (15 สาขา): กลุ่มรายได้สูง มีระดับเงินเดือนสูงคล้ายกันอย่างต่อเนื่อง เช่น Computer Science, Economics, Finance และ Engineering

Contents

Project Overview

1 Degrees That Pay Back

2 Salaries By College Type

3 Salaries By Region

Overall Summary

2: Salaries By College Type

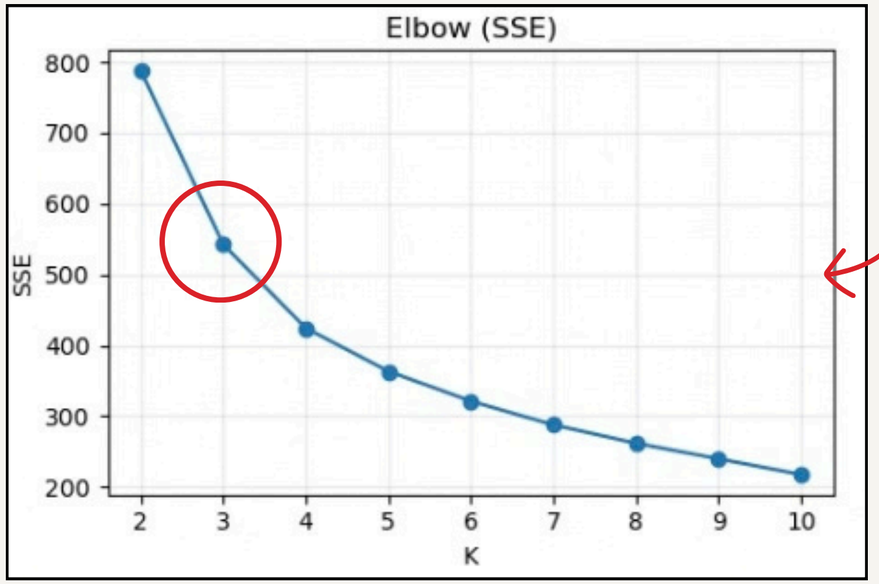
“มหาวิทยาลัยใดมีลักษณะเงินเดือนคล้ายกัน
และมหาวิทยาลัยแต่ละประเภท
กระจายอยู่ในแต่ละกลุ่มอย่างไร”

K-Means

2: Salaries By College Type

Round 1: number of clusters

Experiment	n_clusters	NMI	silhouette
K1	2	0.1572	**0.5180**
K2	3	0.2017	0.3795
K3	4	0.2203	0.3510
K4	5	0.2469	0.3594
K5	6	0.2230	0.3091
K6	7	0.2211	0.3197
K7	8	0.2666	0.3247
K8	9	0.2676	0.3171
K9	10	0.2562	0.2796



Elbow Method

K-Means

2: Salaries By College Type

Round 1: number of clusters

Criteria	K=2	K=3	K=9
Silhouette Score	**0.5180**	0.3795	0.3171
SSE	**778.10**	542.41	239.6
NMI	**0.1572**	0.2017	0.2676
Cluster Size	**[67,202]**	[28, 118, 123]	[2, 5, 7, 11, 14, 27, 30, 77, 96]

- **K=2 ให้ Silhouette สูงสุด** และแบ่งมหาวิทยาลัยเป็น [67, 202] รายการ
- **K=3 จาก Elbow ให้ค่า Silhouette ลดลงมาก** จึงไม่ได้ทำให้โครงสร้าง Cluster ชัดขึ้นตามเกณฑ์หลัก
- **K=9 ให้ NMI สูงสุด 0.2676 แต่ให้ค่า Silhouette ที่ต่ำ** และเกิด Cluster ขนาดเล็ก
- **การแบ่งให้ละเอียดขึ้นสอดคล้องกับ School Type มากขึ้นบางส่วน แต่โครงสร้าง Cluster ไม่ชัดขึ้น**
- จึงเลือก **K=2** เป็น Fixed Parameter ใน Round 2

K-Means

2: Salaries By College Type

Round 2: init × n_init

Experiment	n_clusters	init	n_init	NMI	silhouette
K10	**2**	k-means++	1	**0.1572**	**0.5180**
K11	**2**	k-means++	10	**0.1572**	**0.5180**
K12	**2**	k-means++	20	**0.1572**	**0.5180**
K13	**2**	k-means++	50	**0.1572**	**0.5180**
K14	**2**	random	1	**0.1572**	**0.5180**
K15	**2**	random	10	**0.1572**	**0.5180**
K16	**2**	random	20	**0.1572**	**0.5180**
K17	**2**	random	50	**0.1572**	**0.5180**

K-Means

2: Salaries By College Type

Round 2: init × n_init

init × n_init	NMI	Silhouette	Cluster size	Cluster Profile
All	**0.1572**	**0.5180**	[67,202]	รายได้สูง vs ต่ำ–กลาง

- ทั้ง **8 Experiments ให้ Silhouette, NMI** และ **Cluster Size เหมือนกัน**
- การเปลี่ยน **init และ n_init จึงไม่ส่งผลต่อ Performance** ภายใต้ K=2 และ random state = 42
- อาจเป็นเพราะ โครงสร้างหลักของข้อมูลมีการแบ่งเป็นสองกลุ่มที่ค่อนข้างเด่น ทำให้จุดเริ่มต้นที่ทดลองต่างกันยังลู่เข้าสู่คำตอบเดียวกัน
- จึงเลือก **k-means++, n_init=10** เพราะให้ผลเท่ากันโดย**ไม่ต้องเพิ่มจำนวนการเริ่มต้นมากเกินจำเป็น**

Hierarchical

2: Salaries By College Type

Round 1: number of clusters

Experiment	n_clusters	NMI	silhouette
H1	2	0.2489	**0.6109**
H2	3	0.2043	0.3716
H3	4	0.1871	0.3201
H4	5	0.1985	0.3274
H5	6	0.1941	0.2617
H6	7	0.196	0.2700
H7	8	0.2410	0.2777
H8	9	0.2353	0.2700
H9	10	0.2440	0.2690

Hierarchical

2: Salaries By College Type

Round 1: number of clusters

Criteria	K=2
Silhouette Score	0.6109
NMI	0.2489
Cluster Size	[24, 245]
Cluster Profile	กลุ่มรายได้สูง vs กลุ่มทั่วไป

- **K=2 ให้ทั้ง Silhouette และ NMI สูงสุด**
- **เมื่อเพิ่ม K ค่า Silhouette ลดลงอย่างชัดเจน** และเริ่ม**เกิด Cluster ขนาดเล็ก**
- จึงเลือก **K=2** เป็น Fixed Parameter ใน Round 2

Hierarchical

2: Salaries By College Type

Round 2: linkage × metric

Experiment	n_clusters	linkage	metric	NMI	silhouette
H10	**2**	ward	euclidean	0.2489	**0.6109**
H11	**2**	complete	euclidean	0.1739	0.5101
H12	**2**	complete	manhattan	0.1568	0.5218
H13	**2**	complete	cosine	0.1096	0.3605
H14	**2**	average	euclidean	0.2489	0.6109
H15	**2**	average	manhattan	0.2489	0.6109
H16	**2**	average	cosine	0.1263	0.4002
H17	**2**	single	euclidean	0.0361	0.5761
H18	**2**	single	manhattan	0.0325	**0.6182**
H19	**2**	single	cosine	0.0119	-0.2497

Hierarchical

2: Salaries By College Type

Round 2: linkage × metric

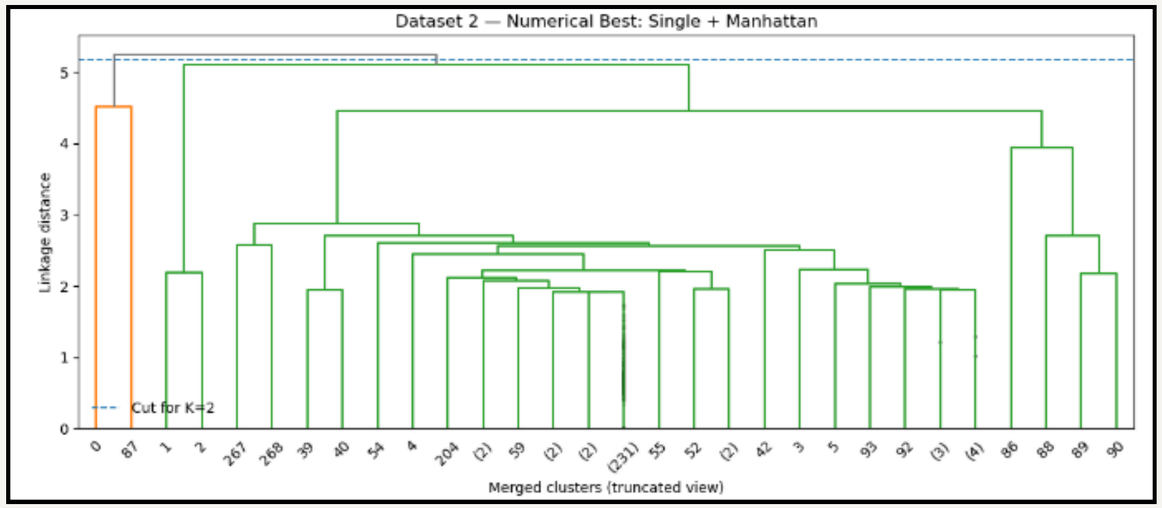
Criteria	NMI	Silhouette	Cluster size	Cluster Profile
Single + Manhattan	0.0325	0.6182	[2 , 267]	กลุ่มรายได้สูงมาก vs กลุ่มทั่วไป
Ward + Euclidean	**0.2489**	**0.6109**	**[24, 245]**	**กลุ่มรายได้สูง vs กลุ่มทั่วไป**

- **Single + Manhattan** ให้ **Silhouette สูงสุด** แต่แบ่ง Cluster เป็นเพียง **[2, 267]**
- **Ward + Euclidean** ให้ Silhouette ใกล้เคียงกัน แต่ได้กลุ่ม **[24, 245]** และมี NMI สูงกว่า

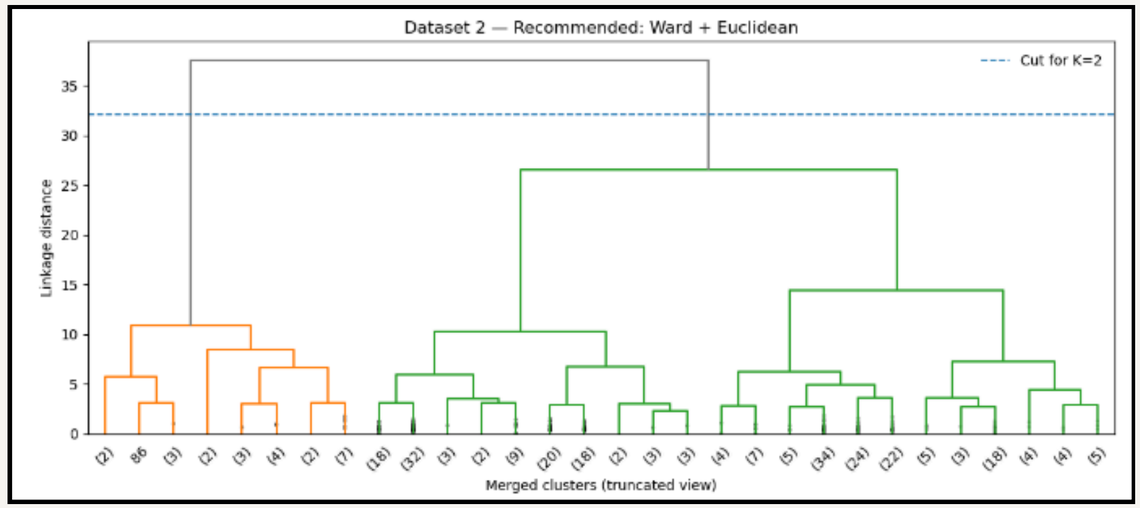
Hierarchical

2: Salaries By College Type

Round 2: linkage × metric



Single + Manhattan [2 , 267]



Ward + Euclidean [24, 245]

- **Single + Manhattan** แสดงการแยก Cluster ขนาดเล็ก คือ **2 มหาวิทยาลัย ออกจากข้อมูลส่วนใหญ่**
- จึงเลือก **Ward + Euclidean** เป็น Final Hierarchical **แม้ไม่ได้มี Silhouette สูงสุดเชิงตัวเลข** แต่ให้ทั้ง**ความชัดเจนของ Cluster และโครงสร้างที่เหมาะสมต่อการตีความมากกว่า**

2: Salaries By College Type

Kmeans vs Hierarchical

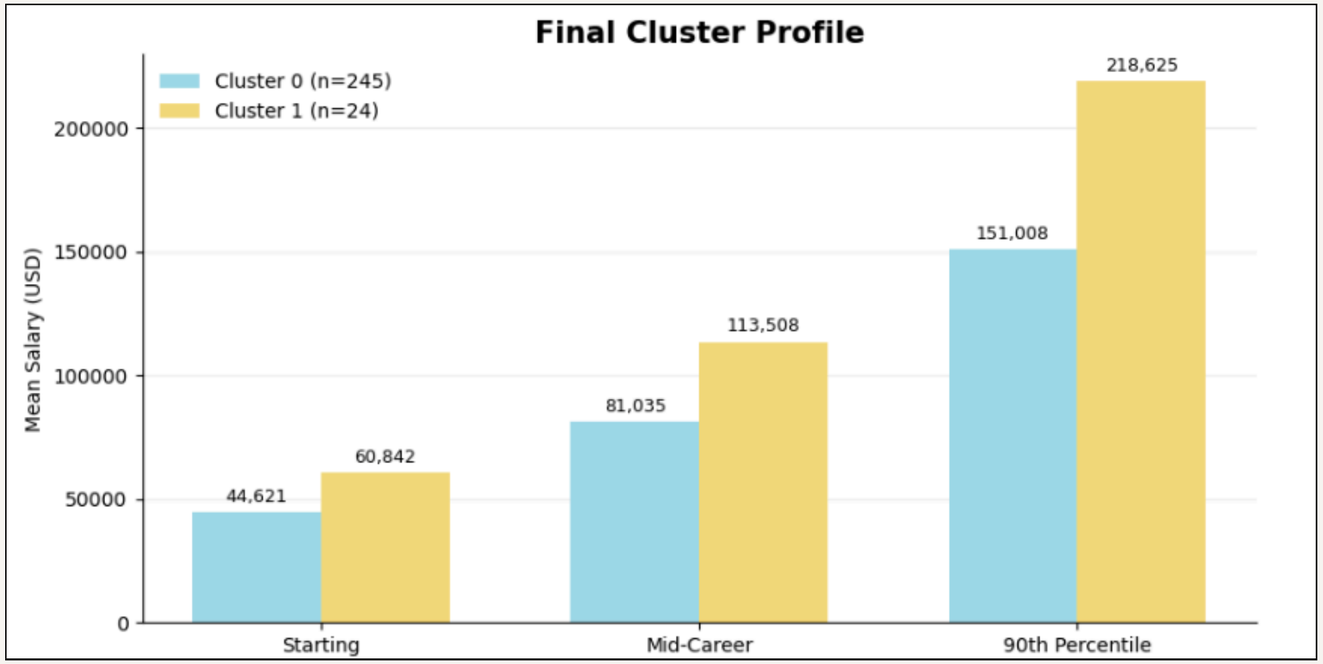
Algorithm	NMI	Silhouette	Cluster Size	Configuration
KMeans	0.1572	0.5180	[67 , 202]	k-means++, n_init=10
Hierarchical	**0.2489**	**0.6109**	**[24, 245]**	**Ward + Euclidean**

- **Hierarchical ให้ Silhouette สูงกว่า KMeans** แสดงว่ากลุ่มมีความ**กระชับ**และ**แยกจากกันได้ชัด**กว่า
- **NMI ค่าค่อนข้างต่ำในทั้ง 2 Alghorithms แสดงว่าความสอดคล้องกับ Ground truth ยังไม่สูง**
- KMeans แบ่งกลุ่มรายได้สูงได้กว้างกว่า ขณะที่ Hierarchical แยกกลุ่มรายได้สูงที่เด่นกว่า
- จึงเลือก **Hierarchical: Ward + Euclidean, K=2** เป็น Best Model

2: Salaries By College Type

Hierarchical

สามารถแบ่งมหาวิทยาลัยตามลักษณะเงินเดือน
ได้เป็น 2 กลุ่มหลัก คือ **กลุ่มรายได้ทั่วไป** และ**กลุ่มรายได้สูง** โดยความแตกต่างหลักอยู่ที่ **ระดับเงินเดือนในแต่ละช่วงอาชีพ** และพบว่า
School Type มีความสอดคล้องกับการแบ่งกลุ่มเพียงบางส่วน



Cluster 0 (245 มหาวิทยาลัย):
กลุ่มรายได้ทั่วไป มีระดับเงินเดือนใกล้เคียงกันในช่วงทั่วไป และประกอบด้วยมหาวิทยาลัยจาก หลาย School Type

Cluster 1 (24 มหาวิทยาลัย):
กลุ่มรายได้สูง มีระดับเงินเดือนสูงอย่างต่อเนื่องในแต่ละช่วงอาชีพ โดยพบมหาวิทยาลัยประเภท Ivy League และ Engineering อยู่ในกลุ่มนี้หลายแห่ง

Contents

Project Overview

1 Degrees That Pay Back

2 Salaries By College Type

3 Salaries By Region

Overall Summary

3: Salaries By Region

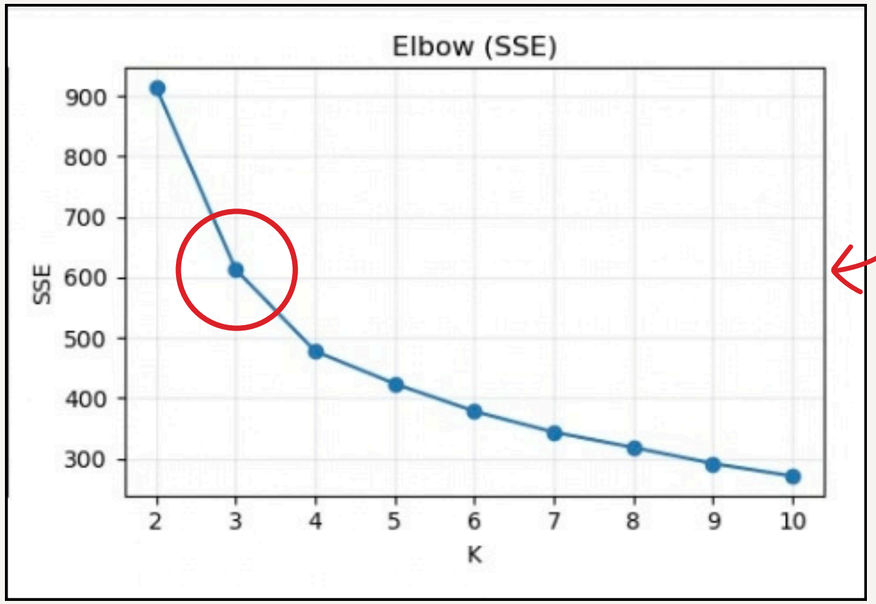
“มหาวิทยาลัยใดมีลักษณะเงินเดือนคล้ายกัน
และมหาวิทยาลัยแต่ละภูมิภาค
กระจายอยู่ในแต่ละกลุ่มอย่างไร”

K-Means

3: Salaries By Region

Round 1: number of clusters

Experiment	n_clusters	NMI	silhouette
K1	2	0.0529	**0.4949**
K2	3	0.0533	0.3856
K3	4	0.0724	0.3426
K4	5	0.0709	0.3429
K5	6	0.0578	0.2842
K6	7	0.0685	0.2918
K7	8	0.0731	0.2844
K8	9	0.0734	0.297
K9	10	0.0947	0.2388



Elbow Method

K-Means

3: Salaries By Region

Round 1: number of clusters

Criteria	K=2	K=3	K=10
Silhouette Score	**0.4949**	0.3865	0.2388
SSE	914.24	613.164	271.24
NMI	0.0529	0.0533	**0.0947**
Cluster Size	**[90 , 230]**	[35, 135, 150]	[2, 6, 10, 13, 14, 32, 44, 55, 68, 76]

- **K=2** ให้ **Silhouette สูงสุด** จึงให้โครงสร้าง Cluster ที่ชัดที่สุดตามเกณฑ์หลัก
- **K=3** อยู่บริเวณ **Elbow แต่ Silhouette ลดลงมาก** จึงไม่ได้ทำให้โครงสร้าง Cluster ชัดขึ้นตามเกณฑ์หลัก
- **K=10** ให้ **NMI สูงสุด แต่ค่า Silhouette ลดลงมาก** และ**เกิดหลาย Cluster ขนาดเล็ก** แสดงว่าการแบ่งละเอียดขึ้น เพิ่มความสอดคล้องกับ Region เพียงเล็กน้อย แต่โครงสร้าง Cluster โดยรวมแย่ลง
- จึงเลือก **K=2 เป็น Fixed Parameter** ใน Round 2

K-Means

3: Salaries By Region

Round 2: init × n_init

Experiment	n_clusters	init	n_init	NMI	silhouette
K10	**2**	k-means++	1	**0.0529**	**0.4949**
K11	**2**	k-means++	10	**0.0529**	**0.4949**
K12	**2**	k-means++	20	**0.0529**	**0.4949**
K13	**2**	k-means++	50	**0.0529**	**0.4949**
K14	**2**	random	1	**0.0529**	**0.4949**
K15	**2**	random	10	**0.0529**	**0.4949**
K16	**2**	random	20	**0.0529**	**0.4949**
K17	**2**	random	50	**0.0529**	**0.4949**

K-Means

3: Salaries By Region

Round 2: init × n_init

init × n_init	NMI	Silhouette	Cluster size	Cluster Profile
All	**0.0529**	**0.4949**	[90, 230]	กลุ่มรายได้สูง vs กลุ่มทั่วไป

- ทั้ง **8 Experiment ให้ Silhouette, NMI** และ **Cluster Size เหมือนกัน**
- การเปลี่ยน **init และ n_init จึงไม่ส่งผลต่อ Performance** ภายใต้ K=2 และ random state = 42
- อาจเป็นเพราะ โครงสร้างหลักของข้อมูลมีการแบ่งเป็นสองกลุ่มที่ค่อนข้างเด่น ทำให้จุดเริ่มต้นที่ทดลองต่างกันยังลู่เข้าสู่คำตอบเดียวกัน
- จึงเลือก **k-means++, n_init=10** เพราะให้ผลเท่ากันโดย**ไม่ต้องเพิ่มจำนวนการเริ่มต้นมากเกินจำเป็น**

Hierarchical

3: Salaries By Region

Round 1: number of clusters

Experiment	n_clusters	NMI	silhouette
H1	2	0.0270	**0.5852**
H2	3	0.0528	0.3753
H3	4	0.0599	0.3322
H4	5	0.0647	0.3352
H5	6	0.0709	0.2545
H6	7	0.0806	0.2610
H7	8	0.0813	0.2649
H8	9	0.0823	0.2634
H9	10	0.0865	0.2755

Hierarchical

3: Salaries By Region

Round 1: number of clusters

Criteria	K=2	K=10
Silhouette Score	**0.5852**	0.2755
NMI	**0.0270**	0.0865
Cluster Size	**[32, 288]**	[2, 7, 7, 9, 13, 16, 38, 45, 58, 125]

- **K=2 ให้ Silhouette สูงสุดโดดเด่น** แสดงว่าโครงสร้าง **2 Cluster มีความกระชับและแยกจากกันชัดที่สุด**
- **เมื่อเพิ่ม K ค่า Silhouette ลดลงอย่างชัดเจน** ขณะที่ NMI มีแนวโน้มเพิ่มขึ้น
- **K=10 ให้ NMI สูงสุด** แต่ทำให้ Silhouette ลดลงมาก แสดงว่า**การเพิ่มจำนวน Cluster** ทำให้สอดคล้องกับ Region มากขึ้นเพียงเล็กน้อย แต่**โครงสร้าง Cluster โดยรวมไม่ชัดขึ้น**
- จึงเลือก **K=2** เป็น Fixed Parameter ใน Round 2

Hierarchical

3: Salaries By Region

Round 2: linkage × metric

Experiment	n_clusters	linkage	metric	NMI	silhouette
H10	**2**	ward	euclidean	0.0270	0.5852
H11	**2**	complete	euclidean	0.0270	0.5852
H12	**2**	complete	manhattan	0.0334	0.5854
H13	**2**	complete	cosine	0.0720	0.3997
H14	**2**	average	euclidean	0.0270	0.5852
H15	**2**	average	manhattan	0.0332	**0.6042**
H16	**2**	average	cosine	0.0734	0.4029
H17	**2**	single	euclidean	0.0198	0.5482
H18	**2**	single	manhattan	0.0198	0.5482
H19	**2**	single	cosine	0.0047	-0.259

Hierarchical

3: Salaries By Region

Round 2: linkage × metric

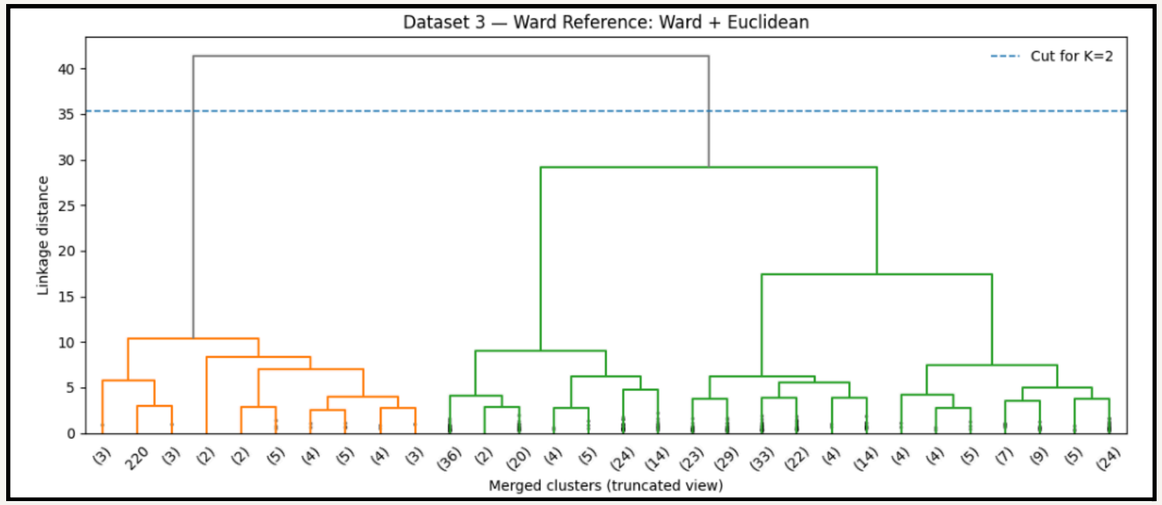
Criteria	Ward + Euclidean	Average + Manhattan	Average + Cosine
Silhouette Score	0.5852	**0.6042**	0.4029
NMI	0.027	**0.0332**	0.0734
Cluster Size	[32, 288]	**[9, 311]**	[140, 180]

- **Average + Manhattan ให้ Silhouette สูงสุด** แต่แบ่งเป็น [9, 311]
- จึงนำ **Ward + Euclidean** [32, 288] ซึ่ง**ให้ Silhouette รองลงมา มาเปรียบเทียบเพิ่มเติม**
- Average + Cosine ให้ NMI สูงสุด แต่ค่า Silhouette ยังค่อนข้างต่ำ จึงไม่ได้ใช้เป็นเกณฑ์หลักในการเลือก Configuration

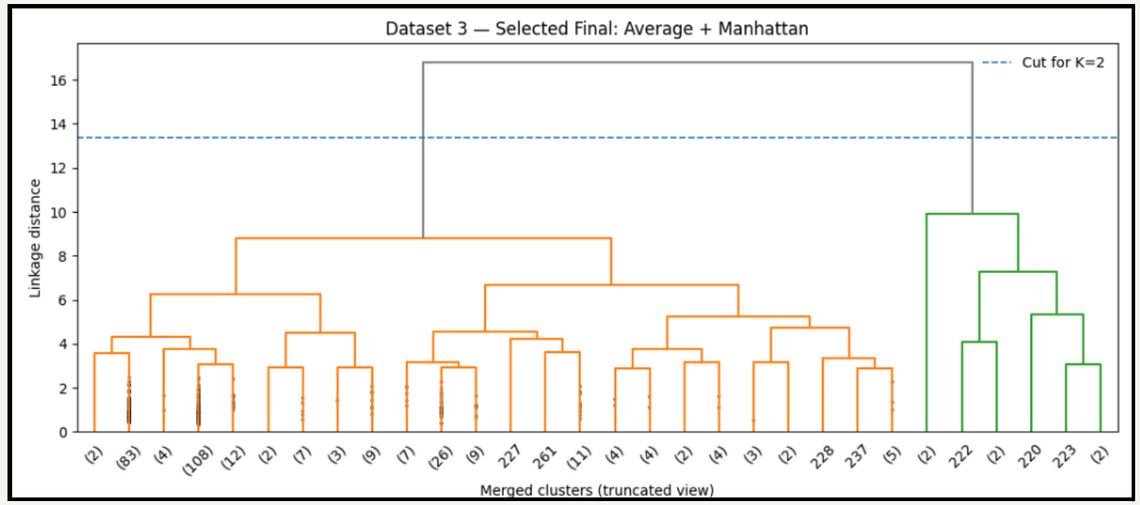
Hierarchical

3: Salaries By Region

Round 2: linkage × metric



Ward + Euclidean [32, 288]



Average +Manhattan [9, 311]

- แม้ **Average + Manhattan จะแบ่งกลุ่มขนาดเล็ก 9 แห่ง** แต่ **Dendrogram** และ **Cluster Profile สนับสนุน**ว่าเป็น **กลุ่มที่มีโครงสร้างและมีระดับเงินเดือนสูงเด่นอย่างชัดเจน**
- จึงเลือก **Average + Manhattan** เป็น Final Hierarchical

3: Salaries By Region

Kmeans vs Hierarchical

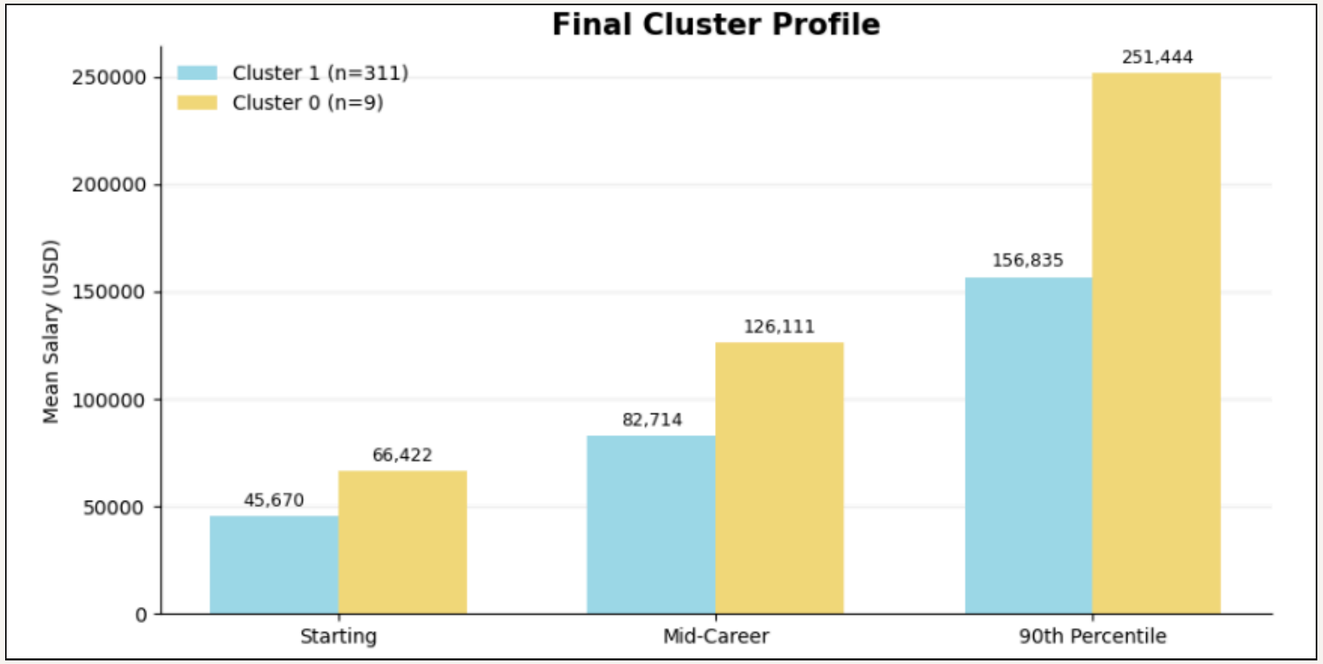
Algorithm	NMI	Silhouette	Cluster Size	Configuration
KMeans	0.0529	0.4949	[90, 230]	k-means++, n_init=10
Hierarchical	**0.0332**	**0.6042**	**[9, 311]**	**Average + Manhattan**

- **Hierarchical ให้ Silhouette สูงกว่า KMeans** แสดงว่าสามารถแยกโครงสร้าง Salary Profile ได้ชัดกว่า
- **KMeans** ให้ **NMI สูงกว่าเล็กน้อย** แต่ NMI ของทั้งสองโมเดล**อยู่ในระดับต่ำ**
- แสดงว่ากลุ่มจาก Salary Features **มีความสอดคล้องกับ Region ค่อนข้างน้อย**
- เนื่องจาก Silhouette เป็นเกณฑ์หลัก และกลุ่ม 9 แห่งสามารถตีความจาก Salary Profile
- จึงเลือก **Hierarchical: Average + Manhattan, K=2** เป็น Best Model

3: Salaries By Region

Hierarchical

สามารถแบ่งมหาวิทยาลัยตามลักษณะเงินเดือน
ได้เป็น **2 กลุ่มหลัก** คือ **กลุ่มรายได้สูงมาก** และ**กลุ่มรายได้ทั่วไป**
โดยความแตกต่างหลักอยู่ที่ **ระดับเงินเดือนในแต่ละช่วงอาชีพ**
ขณะที่ **Region มีความสอดคล้องกับการแบ่งกลุ่มค่อนข้างต่ำ**



Cluster 0 (9 มหาวิทยาลัย):
กลุ่มรายได้สูงมาก
มีระดับเงินเดือนสูงอย่างต่อเนื่องในแต่ละช่วงอาชีพ โดยพบมหาลัย เช่น Stanford , Yale, Harvard และ CIT เป็นต้น

Cluster 1 (311 มหาวิทยาลัย):
กลุ่มรายได้ทั่วไป
มีระดับเงินเดือนใกล้เคียงกันในระดับทั่วไป และประกอบด้วยมหาวิทยาลัยส่วนใหญ่ของ Dataset จาก หลาย Region

Contents

Project Overview

1 Degrees That Pay Back

2 Salaries By College Type

3 Salaries By Region

Overall Summary

Overall Summary

Dataset	Best K-Means	Silhouette	Best Hierarchical	Silhouette	Final Model
Degrees That Pay Back	K=2, k-means++, n_init=10	0.4577	**K=2, Ward + Euclidean**	**0.4802**	**Hierarchical**
College Type	K=2, k-means++, n_init=10	0.518	**K=2, Ward + Euclidean**	**0.6109**	**Hierarchical**
Region	K=2, k-means++, n_init=10	0.4949	**K=2, Average + Manhattan**	**0.6042**	**Hierarchical**

Overall Summary

- ทั้งสาม Dataset เลือก **K=2 ตาม Silhouette** สะท้อนโครงสร้างหลักของ Salary Profile เป็น **2 กลุ่มหลักตามระดับเงินเดือน**
- **KMeans** ให้ขนาดกลุ่มค่อนข้าง**สมดุลกว่า**
- **Hierarchical** สามารถ**แยกกลุ่มรายได้สูงหรือสูงมากออกมาได้ชัดกว่า**

Overall Summary

- **Hierarchical ให้ Silhouette สูงกว่า KMeans** ในทุก Dataset
- อาจเพราะ **โครงสร้าง**ข้อมูลมีการ**แยกกลุ่มรายได้สูงออกจากกลุ่มหลักค่อนข้างชัด** ซึ่ง Hierarchical สามารถจับโครงสร้างดังกล่าวได้ดีกว่า K-Means ภายใต้ Experiment ที่ทดลอง
- สำหรับ **Dataset ที่มี Ground Truth** ค่า **NMI ค่อนข้างต่ำ**
- แสดงว่า **School Type** และ **Region** ไม่ได้สอดคล้องกับ Cluster ที่สร้างจาก Salary Features อย่างชัดเจน

Limitations

- การทดลองใช้รูปแบบ Sequential Best-step โดย**เลือก Best K จาก Round 1** แล้วนำไปเป็น **Fixed Parameter** เพื่อหา Best Configuration ใน Round 2
- เนื่องจากไม่ได้ทดลองทุก Combination ระหว่าง K และ Parameters จึงอาจพลาด Experiment ที่ให้ **Performance สูงกว่าภายใต้ K ค่าอื่น**
- ดังนั้น **ผลที่ได้จึงเป็น Best Experiment ภายใต้ขอบเขตและลำดับการทดลองที่กำหนด** ไม่ใช่การรับประกันว่าเป็นค่าที่ดีที่สุดจากทุก Combination

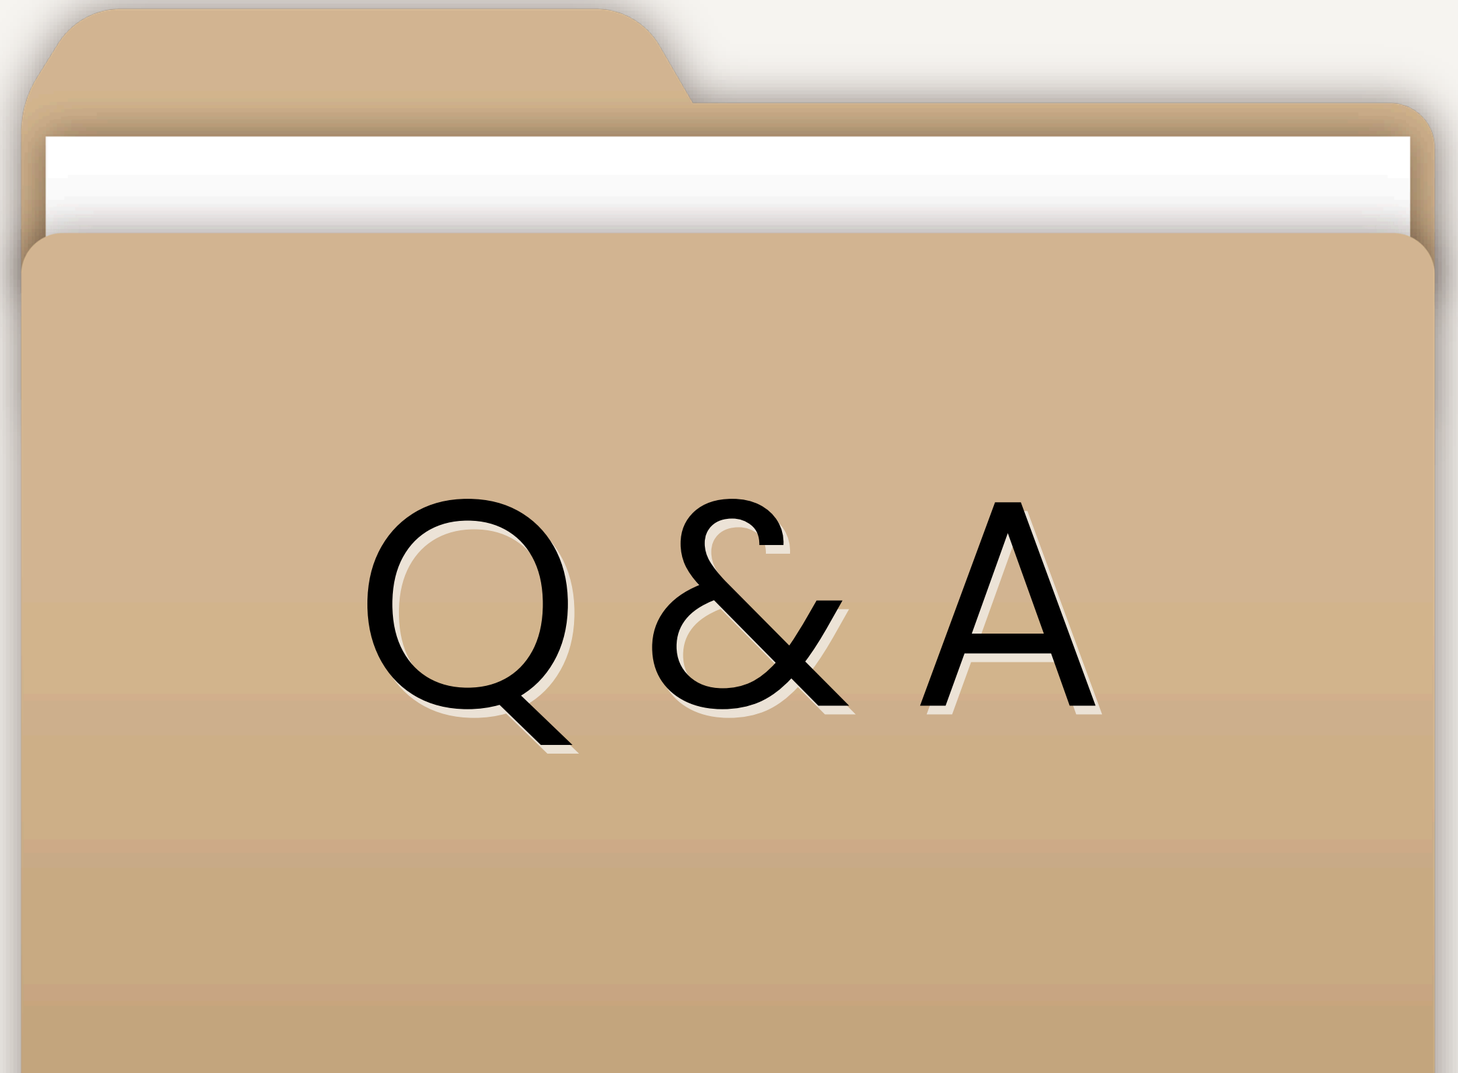
Code Descriptions

Packages	Function	หน้าที่
Pandas	read_csv()	อ่านข้อมูลจากไฟล์ CSV
	fillna()	เติม Missing Values ด้วยค่า Median
	groupby().mean()	คำนวณค่าเฉลี่ยรายกลุ่มเพื่อสร้าง Cluster Profile
	value_counts()	นับจำนวน Instances ในแต่ละคลัสเตอร์
Scikit-learn	StandardScaler()	Standardization ให้มีค่าเฉลี่ย 0 และส่วนเบี่ยงเบนมาตรฐาน 1
	KMeans()	สร้างโมเดลการจัดกลุ่มด้วยวิธี K-Means Clustering
	AgglomerativeClustering()	สร้างโมเดลการจัดกลุ่มด้วยวิธี Hierarchical Clustering
	silhouette_score()	วัดความกระชับและความแยกออกจากกันของ Cluster
	.inertia_	ดึงค่าSSE มาใช้สนับสนุนการทำ Elbow Plot
Matplotlib	plot()	วาดเส้นกราฟสำหรับElbow Plot และ Dendrogram
	bar()	วาดกราฟแท่งเพื่อแสดงการเปรียบเทียบค่าเฉลี่ยใน Cluster Profile

Members

1. นายนันทวัฒน์ ใจเที่ยง : 67102010399
2. นางสาวนาขวัญ จิตต์เอื้อเฟื้อ : 67102010400
3. นางสาวปุณณภา จึงเปี่ยมสุข : 67102010401




Q & A